Báo cáo thực hành

Sinh viên thực hiện: Lâm Quang Khôi

MSSV: 3122411100 - Lớp: 3122411100

Chủ đề thực hiện: Lab 3 + 4

Lab 1: Preprocessing

1. Mục tiêu

- Nắm bắt quá trình tiền xử lý mô hình NLP.
- Có được góc nhìn xử lý thô về dữ liệu trước khi đi vào các mô hình lớn như Seq2Seq.
- Phân tích từng bước và code có sẵn trong bài.

2. Phương pháp

- Thực hiện theo lab1_handout có sẵn:
    - Các công việc cần làm: Tokenization, Vocabulary contruction, Sentence encoding.

3. Quá trình thực hiện

Dữ liệu sử dụng

Có 4 bộ dữ liệu chính:

- dev.en (bộ lập trình mẫu tiếng Anh).

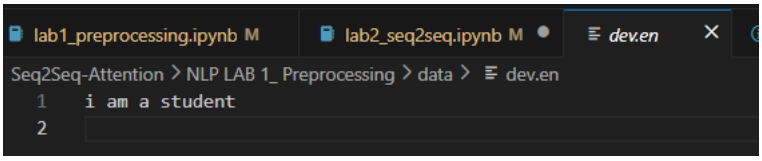

Pic 1. Data dev.en.

- dev.vi (bộ lập trình mẫu tiếng Việt).

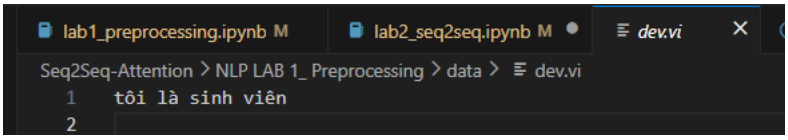

Pic 2. Data dev.vi.

- train.en (bộ huấn luyện tiếng Anh).

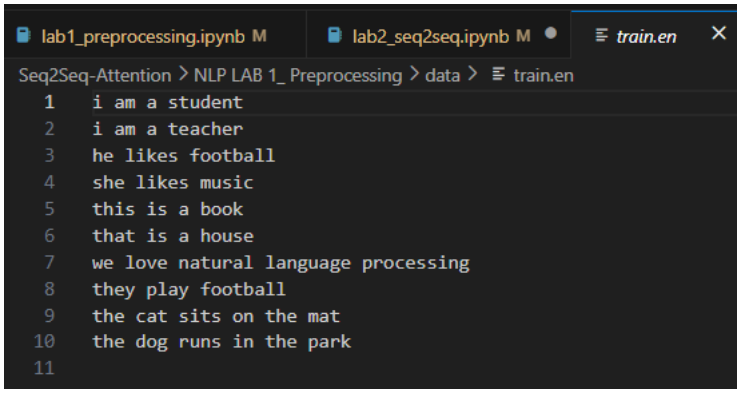

Pic 3. Data train.en.

- train.vi (bộ huấn luyện tiếng Việt).

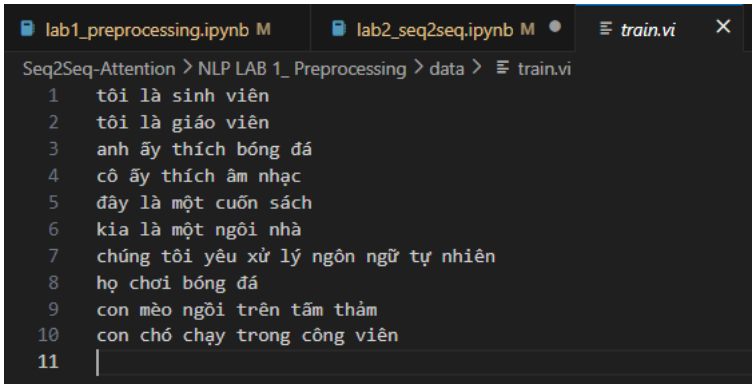

Pic 4. Data train.vi.

➔ **Đánh giá dữ liệu:** Bộ dữ liệu đơn giản để lập trình thử nghiệm.

Phân tích code

Các cell sẵn có:

- Cell 1.

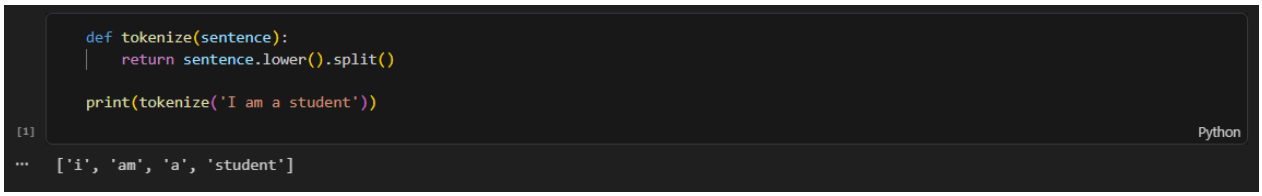

Pic 5. Hình code cell 1.

→ Gọi hàm tokenize về cơ bản thực hiện 2 việc: tách từ trong câu và đưa mỗi từ trong câu thành chữ nhỏ không in hoa

- Cell 2.

Build Vocabulary

```python
class Vocab:
    def __init__(self):
        self.word2id = {}
        self.id2word = {}

    def add_word(self,w):
        if w not in self.word2id:
            idx=len(self.word2id)
            self.word2id[w]=idx
            self.id2word[idx]=w
```

[2] Python

Pic 6. Hình code cell 2.

→Lưu các token vừa chuyển, tạo thành 1 thư viện chứa từ từ sang id và id sang từ

Thực hành code

Các cell cần thực hiện thêm:

- Sử dụng hàm tokenization và vocabulary đã có, ta tạo hàm xây dựng vocabulary lấy được data từ đường dẫn:

```python
# Build vocabulary from training data
def build_vocab(file_paths):
    """
    Build vocabulary from multiple files
    Args:
        file_paths: list of file paths to read
    Returns:
        Vocab object
    """
    vocab = Vocab()

    # Add special tokens first
    vocab.add_word('<PAD>')  # ID: 0 - for padding
    vocab.add_word('<BOS>')  # ID: 1 - begin of sentence
    vocab.add_word('<EOS>')  # ID: 2 - end of sentence
    vocab.add_word('<UNK>')  # ID: 3 - unknown words

    # Read all files and add words
    for file_path in file_paths:
        with open(file_path, 'r', encoding='utf-8') as f:
            for line in f:
                tokens = tokenize(line.strip())
                for token in tokens:
                    vocab.add_word(token)

    return vocab
```

Pic 7. Hàm build_vocab để lấy dữ liệu từ folder data.

- Xây dựng bộ mã hóa câu: chuyển từ chữ sang token, từ token sang chữ

```python
# Encode sentence to sequence of IDs
def encode_sentence(sentence, vocab):
    """
    Encode a sentence to a sequence of token IDs
    Args:
        sentence: input sentence string
        vocab: Vocab object
    Returns:
        list of token IDs
    """
    tokens = tokenize(sentence)

    # Add <BOS> at the beginning
    ids = [vocab.word2id['<BOS>']]

    # Convert each token to ID, use <UNK> if not found
    for token in tokens:
        if token in vocab.word2id:
            ids.append(vocab.word2id[token])
        else:
            ids.append(vocab.word2id['<UNK>'])

    # Add <EOS> at the end
    ids.append(vocab.word2id['<EOS>'])

    return ids
```

Pic 8. Lữu trữ id từ chữ nhận được trong câu

```python
# Decode IDs back to sentence
def decode_sentence(ids, vocab):
    """
    Decode a sequence of IDs back to sentence
    Args:
        ids: list of token IDs
        vocab: Vocab object
    Returns:
        sentence string
    """
    tokens = [vocab.id2word[id] for id in ids]
    return ' '.join(tokens)
```

Pic 9. Giải từ token id sang chữ

4. Kết quả thực hiện

```python
en_vocab_dev = build_vocab(['data/dev.en'])
vi_vocab_dev = build_vocab(['data/dev.vi'])
```

[5] ✓ 0.0s Python

```python
en_vocab_dev.word2id
```

[7] ✓ 0.0s Python

```
{'<PAD>': 0,
 '<BOS>': 1,
 '<EOS>': 2,
 '<UNK>': 3,
 'i': 4,
 'am': 5,
 'a': 6,
 'student': 7}
```

```python
vi_vocab_dev.word2id
```

[8] ✓ 0.0s Python

```
{'<PAD>': 0,
 '<BOS>': 1,
 '<EOS>': 2,
 '<UNK>': 3,
 'tôi': 4,
 'là': 5,
 'sinh': 6,
 'viên': 7}
```

Pic 10. Kết quả ví dụ khi sử dụng hàm xây dựng vocab trên data dev.

```python
# Test encoding and decoding
test_sentence_en = "i am a student"
encoded = encode_sentence(test_sentence_en, en_vocab)
print(f"Original sentence: {test_sentence_en}")
print(f"Encoded: {encoded}")
print(f"Decoded: {decode_sentence(encoded, en_vocab)}")

# Test with Vietnamese
test_sentence_vi = "tôi là sinh viên"
encoded_vi = encode_sentence(test_sentence_vi, vi_vocab)
print(f"\nOriginal sentence: {test_sentence_vi}")
print(f"Encoded: {encoded_vi}")
print(f"Decoded: {decode_sentence(encoded_vi, vi_vocab)}")

# Test with unknown word
test_unknown = "i love python programming"
encoded_unk = encode_sentence(test_unknown, en_vocab)
print(f"\nSentence with unknown words: {test_unknown}")
print(f"Encoded: {encoded_unk}")
print(f"Decoded: {decode_sentence(encoded_unk, en_vocab)}")
print("Note: 'python' and 'programming' are not in training data, so they become <UNK>")
```

[12] ✓ 0.0s Python

```
Original sentence: i am a student
Encoded: [1, 4, 5, 6, 7, 2]
Decoded: <BOS> i am a student <EOS>

Original sentence: tôi là sinh viên
Encoded: [1, 4, 5, 6, 7, 2]
Decoded: <BOS> tôi là sinh viên <EOS>

Sentence with unknown words: i love python programming
Encoded: [1, 4, 20, 3, 3, 2]
Decoded: <BOS> i love <UNK> <UNK> <EOS>
Note: 'python' and 'programming' are not in training data, so they become <UNK>
```

Pic 11. Kết quả để encoding từ câu nhập vào trở thành mã lưu trong encoding,

5. Giá trị rút ra

Tuy khác với thực tế các mỗi từ không được chuyển sang cái token đơn giản như vậy nhưng phần nào giúp hiểu được cách 1 bộ dữ liệu được chuyển sang token ngôn ngữ của

máy học để chúng có thể hiểu được các khái niệm cần thiết. Là bước đầu tiên sau khi khảo sát ngôn ngữ và lấy được nguồn dữ liệu về cho huấn luyện học máy.